

Hospital Readmission Prediction

GROUP 3

風碩二 劉家宏、風碩二 黃奕豪、經四甲 李苡慧、貿四乙 陳昶佳、社會三 蕭博丞

Agenda

- 01 PROBLEM DEFINITION
- 02 EDA
- 03 MODELING
- 04 APPLICATION

01 PROBLEM DEFINITION

專案背景

專案目的	預測病患出院後 14 天內再入院風險			
現況問題	醫院角度 - 病患短期內再次住院會增加床位與醫療資源負擔 - 再入院率也是醫療品質的重要指標		保險公司角度 - 再入院代表醫療支出增加 - 高風險病患可能帶來較高理賠成本	
痛點分析	高風險病患難以提前辨識 院方難以同時評估大量出院病患	醫療資源可能錯配 - 高風險病患未獲得足夠追蹤 - 低風險病患投入過多照護資源	難以量化再入院風險 目前缺乏一致且可量化的風險評估工具，導致後續管理優先順序不易建立	
	——> 若能提前辨識高風險病患，保險公司可規劃健康管理方案，醫院亦可安排出院後追蹤與介入措施，以降低未來醫療成本			
預測模型設計	病患基本資訊 Age, Gender 醫療資訊 Primary Diagnosis, Comorbidity Score, Number of Procedures 住院資訊 Days in Hospital 出院資訊 Discharge Destination		模型輸出 0 = 未再入院 1 = 再入院	模型預期目標 - 找出與 14 天再入院風險相關的病患特徵 - 整合病患基本資料、住院治療負擔與出院去向，建立再入院風險分數 - 協助醫院在病患出院前進行風險分層，辨識需要優先關注的高風險病患

住院醫療費用保險單示範條款-十四天條款

住院醫療費用保險單示範條款（日額型）

第七條

（住院次數之計算及契約有效期間屆滿後住院之處理） 被保險人於本契約有效期間，因同一疾病或傷害，或因此引起之併發症，於出院後十四日內於同一醫院再次住院時，其各種保險金給付合計額，視為一次住院辦理。

14天內再入院住院天數累計(設有單次入院天數上限)

住院醫療費用保險單示範條款（實支實付型）

第十條









（住院次數之計算及契約有效期間屆滿後住院之處理） 被保險人於本契約有效期間，因同一疾病或傷害，或因此引起之併發症，於出院後十四日內於同一醫院再次住院時，其各種保險金給付合計額，視為一次住院辦理。

14天內再入院共用限額

02 EDA

資料簡介 | 僅 readmitted 資料不平衡，後續僅針對此進行處理

訓練資料共 5,000 筆、8 個欄位，無缺失值，各欄位分配均平均

欄位名稱	age	gender	primary_diagnosis	num_procedures	days_in_hospital	comorbidity_score	discharge_to	readmitted
	年齡	性別	主要診斷	療程次數	住院天數	共病指數	出院地點	再入院與否
說明	18~89 歲	女：2,519 筆 男：2,481 筆	1 Kidney Disease 2 Diabetes 3 COPD 4 Hypertension 5 Heart Disease	0~9 次	1~14天	衡量患者有無其他額外疾病的分數 介於 0~4	1 返回家中 2 復健機構 3 療養院 4 居家照護	出院後 14 天內是否再入院： 1 = 再入院 0 = 未再入院
資料型態	int64	object	object	in64	in64	in64	object	in64
								

資料 EDA | 7 個原始變數對 readmitted 的單變數檢定皆不顯著

沒有單一變數能直接解釋 readmitted 的差異，後續仍進行特徵工程與機器學習建模，理由是：

- ML 模型有機會捕捉到變數之間的非線性與交互作用關係
- 這類關係無法被單變數的卡方檢定/t檢定偵測出來，因此值得進一步嘗試

```
=====
類別型變數 vs readmitted -> 卡方獨立性檢定 (Chi-square test)
H0: 該類別變數與 readmitted 互相獨立 (無關聯)
=====
```

gender	chi2=	1.168	dof=1	p-value=0.2798
primary_diagnosis	chi2=	2.041	dof=4	p-value=0.7282
discharge_to	chi2=	2.160	dof=3	p-value=0.5399

```
=====
連續型變數 vs readmitted -> 獨立樣本 t 檢定 (Welch's t-test)
H0: readmitted=0 與 readmitted=1 兩組的平均值相等
=====
```

age	mean(0)=	53.283	mean(1)=	53.368	t=	-0.113	p-value=0.9099
num_procedures	mean(0)=	4.465	mean(1)=	4.445	t=	0.196	p-value=0.8447
days_in_hospital	mean(0)=	7.416	mean(1)=	7.315	t=	0.689	p-value=0.4909
comorbidity_score	mean(0)=	2.069	mean(1)=	2.065	t=	0.088	p-value=0.9296

處理資料不平衡(readmitted)

不採樣 (3248:752)

Baseline

保留訓練集原始比例，作為後續模型比較基準

上採樣 (3248:3248)

Random Over

隨機複製「再入院」樣本，使兩類數量平衡

下採樣 (752:752)

Random Under

隨機刪除部分「未再入院」樣本，使兩類數量平衡

合成採樣 (3248:3248)

SMOTE

One-Hot Encoding 後，透過鄰近樣本合成新「再入院」樣本

SMOTEENC

保留類別欄位特性，針對混合型資料合成新的「再入院」樣本

03 MODELING

Base Model建立 | 選擇羅吉斯回歸/隨機森林/XGBoost/SVM模型

專案目標：預測病患出院 14 天內是否再住院，為分類問題

建模流程

1 資料前處理

- 拆分訓練與測試集 (8:2)
- One-Hot Encoding
- 平衡資料處理 (採樣)

2 初步模型成效

- Logistic Regression
- Random Forest
- XGBoost
- SVM

3 模型優化

- 特徵工程
- Threshold Optimization

4 優化後模型

- Logistic Regression
- Random Forest
- XGBoost
- SVM

5 模型評估指標比較

- Recall
- F1-score
- ROC-AUC

6 最終模型選擇

Logistic Regression

資料前處理

① 類別不平衡處理

- 訓練集未再入院 4,060 筆 (81.2%) / 再入院 940 筆 (18.8%)，存在明顯不平衡
- 採用 SMOTE 過採樣於訓練階段進行平衡，模型評估以 Recall、F1、ROC-AUC 為主要指標

② One-Hot Encoding

gender、primary_diagnosis、discharge_to 三個類別型欄位轉為虛擬變數，原始 7 個特徵擴展為 15 個特徵

③ 訓練集切分

- train_df (5,000 筆) 依 80/20 切分為訓練集與驗證集，已找到最佳 Threshold
- 驗證集用於搜尋最佳分類門檻 (threshold)，test_df (2,000 筆) 作為最終評估

初步模型結果 | 普遍存在 Recall 偏低、AUC 接近隨機預測的問題

	採樣方法	Threshold	AUC	Accuracy	Precision	Recall	F-1 Score
羅吉斯回歸	SMOTEENN	0.1	0.5007	0.4860	0.4860	1.000	0.6541
隨機森林	RandomUnderSampler	0.25	0.4938	0.4810	0.4830	0.965	0.6438
XGBoost	SMOTEENN	0.1	0.4875	0.4825	0.4837	0.964	0.6442
SVM	RandomUnderSampler	0.1	0.5175	0.4860	0.4860	1.000	0.6541

模型優化策略

特徵工程

- Age Group
- Diagnosis Group
- Stay Bucket
- Long Stay
- High Risk Comorbidity
- Interaction Features

Threshold Optimization






搜尋最佳 Threshold Maximize F1 Score，
資料存在類別不平衡，因此用以提升少數類別辨識能力

模型優化策略-特徵工程

假設住院歷程、疾病特性與健康複雜度可能影響再入院風險


類別	特徵類型	建立方式	Note
分組特徵	age_group	age 切分為 5 組 18-30／31-45／46-60／61-75／76+	捕捉年齡非線性效應
	stay_bucket	days_in_hospital 切分為 3 組 0-3／4-7／8+ 天	反映住院長短的臨床意義
	procedure_category	num_procedures 切分為 5 組 None／1-2／3-4／5-6／7+	避免單一極端值影響
二元旗標	long_stay	Days in Hospital > 7 → 1；否則 0	快速標記長住院高風險
	high_risk_comorbidity	Comorbidity Score ≥ 3 → 1；否則 0	標記高共病風險病患
交互作用	Age × Comorbidity		捕捉多重風險因素共同影響 - 年齡與共病的交互影響 - 年齡與治療強度的交互影響 - 疾病複雜度與治療強度的交互影響
	Procedures × Age		
	Procedures × Comorbidity		

模型優化策略-特徵工程 EDA




模型優化策略-特徵工程 EDA


Age x Comorbidity



Procedures x Age



Procedures x Comorbidity



調整後模型比較 | Logistic Regression 模型為最適結果

- 本專案以**降低高風險病患漏判率、提高再入院病患辨識能力**為主要目標，因此優先考量 Recall、F1-score、ROC-AUC，綜合評估後 Logistic Regression 為最適合之模型
- Logistic Regression 的 AUC 最高，F1-score 達 0.654，Recall 達 0.999，Threshold 調整至 0.35 後能有效辨識絕大多數再入院病患，符合降低漏判的需求。
- 不過四個模型的 AUC 均落於 0.49–0.52 之間，差距未達統計顯著水準，模型整體區辨能力有限，此結果反映資料集本身的訊號強度不足

	採樣方法	Threshold	AUC	Accuracy	Precision	Recall	F-1 Score
羅吉斯回歸	SMOTE	0.35	0.5112	0.4860	0.4860	0.9990	0.6539
隨機森林	Random Under Sampler	0.25	0.5061	0.4795	0.4823	0.9660	0.6434
XGBoost	SMOTE	0.1	0.4905	0.4810	0.4825	0.9362	0.6368
SVM	SMOTEENN	0.1	0.5048	0.5025	0.4909	0.6368	0.5544

Logistic Regression 模型優化歷程

優化流程	原始模型 → SMOTE → 特徵工程 → Threshold Tuning → Logistic Regression					
觀察	改善類別不平衡問題 SMOTE 與 Threshold Optimization 為模型提升的主要來源					
觀察	處理方式	Threshold	Recall	F1	ROC-AUC	重點發現
	Baseline	0.5	0	0	0.491	模型完全偏向多數類，再入院病患全數漏判
	+ SMOTE	0.5	0.515	0.5	0.496	改善類別不平衡，少數類開始被辨識
	+ Feature Engineering	0.5	0.49	0.49	0.511	AUC 微幅提升至最高點
	+ Threshold Optimization	0.35	0.999	0.65	0.511	大幅提升再入院辨識率，符合醫療風險管理需求

Logistic Regression 模型成效

最終模型設定：Best Threshold = 0.35


Logistic Regression

- 成功辨識 99.9% 再入院病患 (TP=971, FN 僅 1 人)
- 但 99.9% 非再入院病患遭誤判為高風險 (FP=1027)
- 模型實際上近乎預測所有人皆會再入院, Precision 僅 48.6%
- 根本原因: AUC=0.511, 模型缺乏足夠的區辨能力, threshold 調整只能在 Recall/Precision 間取捨, 無法同時改善

Best Threshold = 0.35
ROC-AUC = 0.5112


	precision	recall	f1-score	support
0	0.5000	0.0010	0.0019	1028
1	0.4860	0.9990	0.6539	972
accuracy			0.4860	2000
macro avg	0.4930	0.5000	0.3279	2000
weighted avg	0.4932	0.4860	0.3188	2000

Confusion Matrix



模型調整後結果 | 年齡與共病程度主導模型判斷，強化非線性年齡效應

- Logistic Regression 的係數顯示，**年齡與共病分數**為最具影響力變數
- 特徵工程後，age_group 分組特徵與 age×comorbidity 交互作用項同步進入 Top 6，使模型能捕捉「不同年齡段的共病風險差異」，而非僅依賴線性的年齡數值



模型小結

儘管特徵重要性指向年齡與共病，AUC 僅達 0.511，顯示這些特徵尚不足以有效區辨再入院與否。結合 Confusion Matrix 可見，模型在 threshold 調降後雖達 99.9% Recall，但同時將 99.9% 非再入院病患誤標為高風險——此現象反映的是資料本身的訊號不足，而非特徵選擇或模型架構的問題。

04 APPLICATION

商業應用建議 | 以再住院風險模型建立高風險保戶預警系統

模型洞察：從病患資料轉成保險風險分數

- 本研究分析 5,000 筆病患資料，測試集中 188 / 1,000 人於 14 天內再住院，再住院率約 18.8%
- 高風險共病族群占 42.6%，長住院族群占 48.8%，顯示近半數病患具備較高照護需求
- 接受 5 次以上處置者占 49.4%，代表治療強度可作為風險判斷依據

商業推論：保險公司可以提前辨識高理賠風險保戶

- 若同時具有「長住院、共病、處置次數高」等特徵，代表其出院後仍可能需要密集醫療照護
- 這類保戶若未被追蹤，可能在短期內產生再次住院與理賠
- 保險公司可將再住院模型作為「高理賠風險預警工具」
- 模型不取代核保或醫師判斷，協助保險公司建立優先追蹤名單

實際應用：建立高風險保戶名單

- 系統依住院天數、疾病類型、處置次數與共病狀態產生風險分數
- 高風險者進入「出院後 14 天追蹤名單」
- 中風險者進入「用藥提醒與回診提醒名單」
- 低風險者維持一般衛教與數位通知
- 優先處理最可能產生後續理賠的族群

現實可行性：保險公司已有導入基礎

- 保險公司本來就擁合理賠紀錄、住院紀錄與保戶基本資料
- 出院後關懷、健康管理、遠距諮詢與個案管理為可延伸的服務場景
- 本模型可作為第一階段風險篩選工具，協助健康管理團隊決定先追蹤誰
- 目標是輔助分流，而非直接拒保或調整保費，落地阻力較低

協助保險公司提前辨識高理賠風險保戶，集中介入資源，降低 14 天內再住院與後續理賠成本

商業應用流程 | 從再住院預測到保險理賠成本控管

從資料洞察到商業決策：提前辨識風險、主動介入、降低理賠成本

保險公司的問題不是「能不能完美預測每一位保戶是否再住院」，而是「能不能比傳統流程更早找出高風險保戶」。
本研究模型的價值在於：透過高 Recall 設定，盡可能降低漏掉再住院保戶的機率，讓保險公司能提前介入可能產生高額理賠的族群

模型結果	商業效益估算	落地流程
Precision 為 48.6%，相較原始再住院率 18.8%，高風險名單命中率約提升至 2.6 倍 AUC 約 0.5112，代表模型仍不適合單獨作為最終決策工具 作為第一層篩選工具，而非自動核保模型	以 1,000 名出院保戶為例，依測試集 18.8% 再住院率，約有 188 人可能再住院 若健康管理介入降低 10%~15% 再住院事件，約可減少 19~28 筆後續理賠 若每筆再住院理賠成本為 C，則可降低約 19C~28C 的理賠壓力	- Step 1 資料匯入：整合住院天數、疾病類型、處置次數、共病狀態與出院去向 - Step 2 風險分層：模型將保戶分為低、中、高風險，作為健康管理優先順序 - Step 3 主動介入：高風險保戶導入護理師關懷、用藥提醒、回診提醒與遠距諮詢 - Step 4 追蹤成效：比較介入前後的 14 天再住院率與理賠金額，持續優化模型

透過 99.9% Recall 提前找出潛在再住院保戶，再由健康管理團隊主動介入，降低 14 天內再住院與後續理賠成本。